Rapport de Projet

Analyse des Performances en Premier League

Toutes les victoires se valent-elles vraiment ?

Carl Fléreau — Data Analyst

2026

Table des matières

1. Présentation du projet 3
Contexte et problématique 3
Périmètre et données 3
Architecture du projet 3
2. Ingestion et nettoyage des données 4
Collecte par scraping (FBref) 4
Nettoyage et structuration 4
Statistiques descriptives — Power BI 4
3. Feature Engineering 5
Objectif 5
Calcul de la forme récente 5
Variables de pression et d'enjeu classement 6
Rivalités 7
Récupération physique 8
Contexte 8
Affluence 8
Variable cible 8
4. Modélisation — Conclusion 9
Approche et choix du modèle 9
Variables retenues 9
Résultats, performance et limites 9
Conclusion générale 13

1. Présentation du projet

Contexte et problématique

Ce projet s'inscrit dans une démarche d'analyse sportive appliquée à la Premier League sur les dix dernières saisons. Plutôt que de s'en tenir aux classements finaux, qui masquent souvent la réalité de la compétition, l'objectif est de répondre à une question plus fine :

« Toutes les victoires se valent-elles vraiment ? »

Un résultat face à une équipe en pleine dynamique n'a pas le même poids qu'une victoire contre une équipe en difficulté. Ce projet vise donc à évaluer les performances des équipes en tenant compte de la forme réelle des adversaires au moment du match, et non uniquement du classement.

Périmètre et données

Les données couvrent 10 saisons de Premier League (2014-2015 à 2023-2024), soit plusieurs milliers de matchs. Elles ont été collectées via le scraping du site FBref, référence reconnue pour la richesse de ses statistiques football match par match. La granularité de la donnée permet une analyse au niveau de chaque équipe pour chaque rencontre.

Architecture du projet

Le projet est structuré en trois étapes distinctes, chacune faisant l'objet d'un notebook dédié :

- 1 — Ingestion & Nettoyage : scraping, harmonisation et construction du dataset
- 2 — Feature Engineering : construction des variables analytiques
- 3 — Modélisation : entraînement et évaluation d'un modèle prédictif

2. Ingestion et nettoyage des données

Collecte par scraping (FBref)

La première étape du projet consiste à récupérer les données brutes depuis le site FBref. Cette phase, souvent invisible dans les analyses finales, est pourtant fondamentale : sans données fiables et cohérentes, aucune conclusion ne l'est. Le scraping a été réalisé en Python, en ciblant les tables de résultats match par match disponibles pour chaque saison.

Les données extraites incluent notamment : les équipes (domicile et extérieur), la date et la journée de championnat, les scores, les affluences, ainsi que diverses statistiques de match. Une attention particulière a été portée aux tables encodées dans des commentaires HTML, nécessitant un traitement spécifique pour être correctement extraites.

Nettoyage et structuration

Une fois les données collectées, un pipeline de nettoyage a été appliqué pour construire un dataset propre et exploitable. Les principales opérations réalisées sont les suivantes :

- Standardisation des noms de colonnes (minuscules, suppression des caractères spéciaux)
- Suppression des colonnes non pertinentes pour l'analyse (notes, liens de rapport de match)
- Typage correct des variables : conversion des dates au format datetime, des journées en entier, etc.
- Construction d'une clé unique par match (match_id) et par équipe-match (mw_id)

Statistiques descriptives — Power BI

L'exploration statistique des données (distributions, corrélations, évolutions par saison, comparaisons entre équipes) est disponible dans le rapport Power BI associé à ce projet. Ce tableau de bord interactif permet de naviguer dans la donnée et d'en visualiser les principales caractéristiques sans surcharger ce rapport.

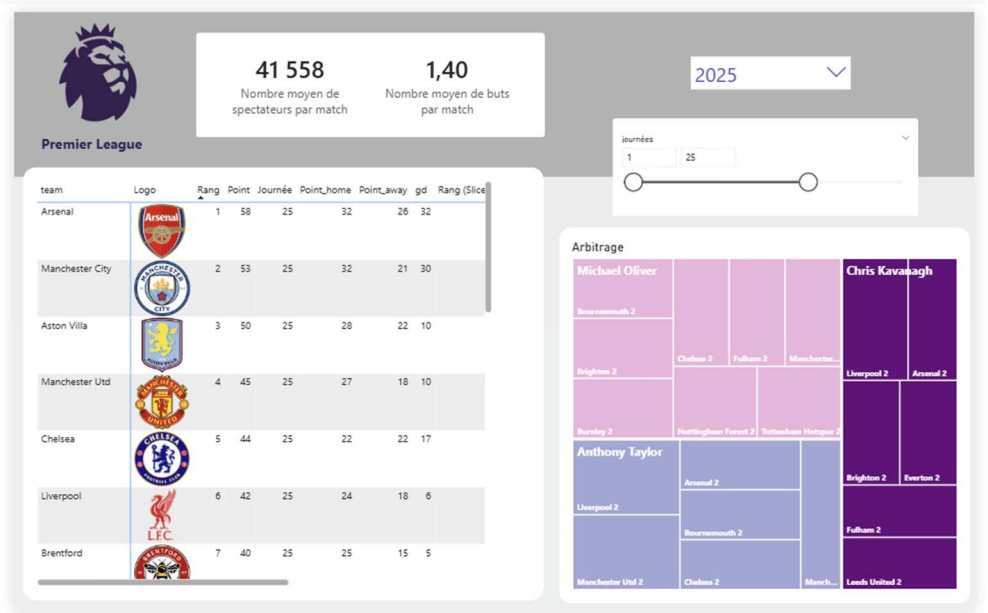

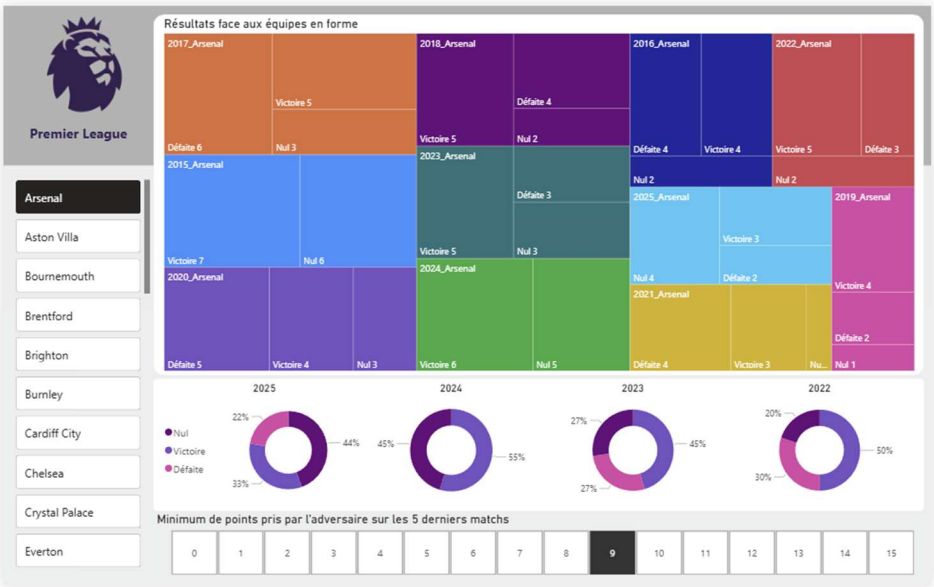

3. Feature Engineering

Objectif

La phase de feature engineering vise à enrichir le dataset avec des variables analytiques plus fines que les simples résultats bruts. L'idée directrice est de capturer le contexte de chaque match : la pression de classement, l'intensité de la rivalité, les conditions physiques des équipes. Ces variables sont construites pour être directement utilisables par le modèle de prédiction.

Calcul de la forme récente

Un élément central du projet est le calcul de la forme des équipes sur les 5 derniers matchs avant chaque rencontre. Ce calcul repose sur une fenêtre glissante (rolling window) avec un décalage d'une observation (shift) pour éviter de prendre en compte le résultat du match en cours. Les indicateurs calculés sont :

- form5_points : points cumulés sur les 5 derniers matchs
- form5_gf et form5_ga : buts marqués et encaissés sur la période
- form5_gd : différentiel de buts sur les 5 derniers matchs

Ces mêmes indicateurs ont ensuite été calculés du côté adverse (préfixe opp_), permettant d'avoir une vision symétrique de la dynamique des deux équipes au moment de chaque match.

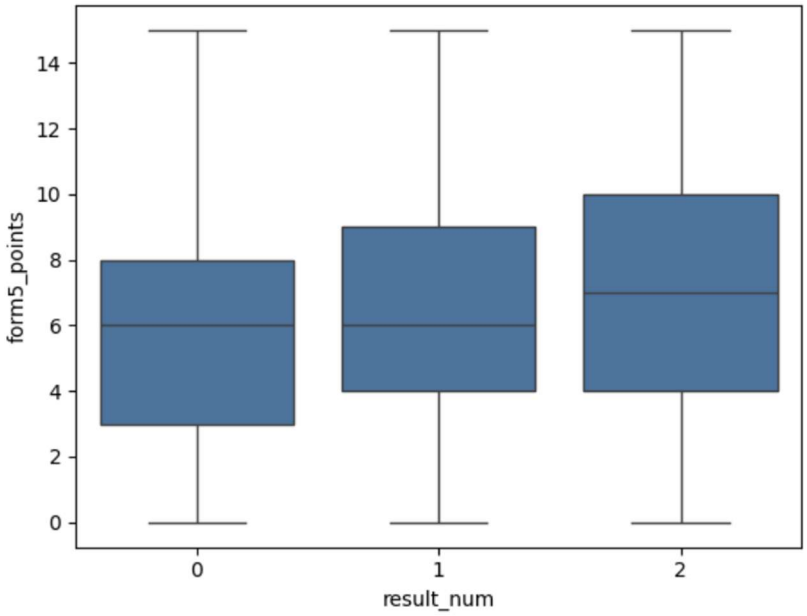

On peut ainsi se rendre compte que plus la moyenne de points pris sur les 5 derniers matchs est élevée, plus il y a de chances que l'équipe gagne.

Variables de pression et d'enjeu classement

À partir du classement à chaque journée, plusieurs variables ont été construites pour mesurer la distance de chaque équipe aux seuils clés du championnat :

- **gap_to_18th** : écart de points avec la zone de relégation (18e place)
- **gap_to_4th** : écart avec la 4e place (qualification Ligue des Champions)
- **gap_to_1st** : écart avec le leader

Des variables binaires de proximité ont ensuite été dérivées (within6_of_safety, within6_of_top4, within6_of_title), indiquant si une équipe se trouve à moins de 6 points d'un seuil. Enfin, des scores de pression (pressure_safety_18th, pressure_top4_4th, pressure_title_1st) combinent ces informations pour quantifier l'enjeu du match pour chaque équipe. L'ensemble de ces variables a également été calculé du côté adverse.

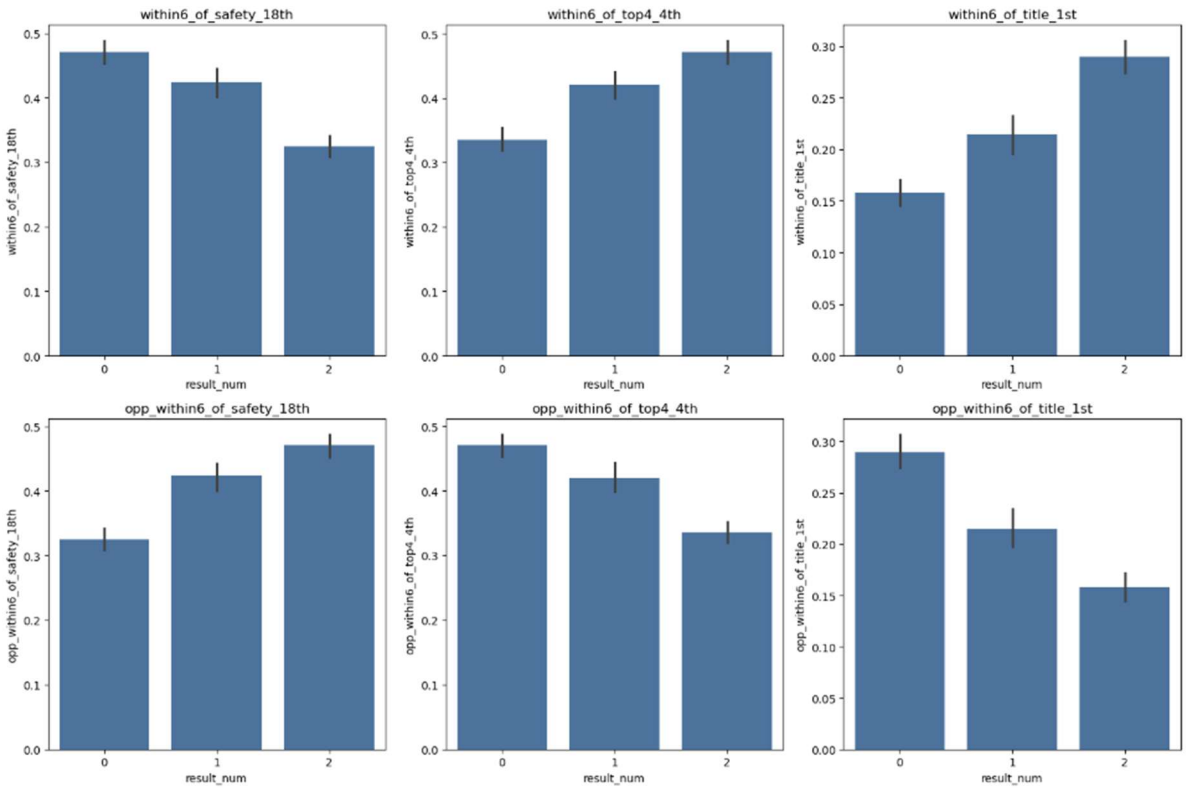

Les 6 graphiques confirment que les variables de proximité aux seuils de classement ont bien un pouvoir discriminant sur le résultat :

a) <u>Côté équipe (ligne du haut)</u>

- **within6_of_safety_18th** : les équipes proches de la zone de relégation perdent plus souvent (0.47 en cas de défaite vs 0.33 en cas de victoire) — la pression de survie ne se traduit pas en performance.
- **within6_of_top4_4th** et **within6_of_title_1st** : pattern inverse — plus l'équipe est proche du top, plus elle gagne. Les équipes dans la course au titre ont une probabilité de victoire nettement plus élevée (0.28 vs 0.16).

b) <u>Côté adversaire (ligne du bas)</u>

- Les patterns se renversent symétriquement : quand l'adversaire est proche du top 4 ou du titre, l'équipe concernée gagne moins souvent. Quand l'adversaire est en zone de relégation, elle gagne plus.

En résumé, ces variables capturent bien la hiérarchie sportive du moment, et leur symétrie équipe/adversaire valide la cohérence de la construction.

Rivalités

Une variable de rivalité a été intégrée pour capturer l'intensité historique entre certains clubs. Les derbys et confrontations à fort enjeu (Manchester United vs Liverpool, Arsenal vs Tottenham, etc.) sont encodés avec une intensité forte, moyenne ou neutre selon leur degré de rivalité. L'hypothèse est que ces matchs peuvent générer des performances atypiques par rapport au niveau attendu des deux équipes.

Récupération physique

Le nombre de jours écoulés depuis le match précédent (rest_days) a été calculé par équipe et par saison. Cette variable, ensuite catégorisée (moins de 3 jours, 4 à 5 jours, 6 jours et plus), permet de modéliser l'impact de la fatigue physique sur la performance, notamment en période de calendrier chargé.

Contexte

Une variable binaire is_home indique si l'équipe joue à domicile ou à l'extérieur. En effet, chaque club dispute exactement la moitié de ses matchs à domicile et l'autre moitié à l'extérieur sur une saison. Cette variable permet au modèle de capter l'avantage du terrain dans la mesure ou la tactique peut être différente selon la situation.

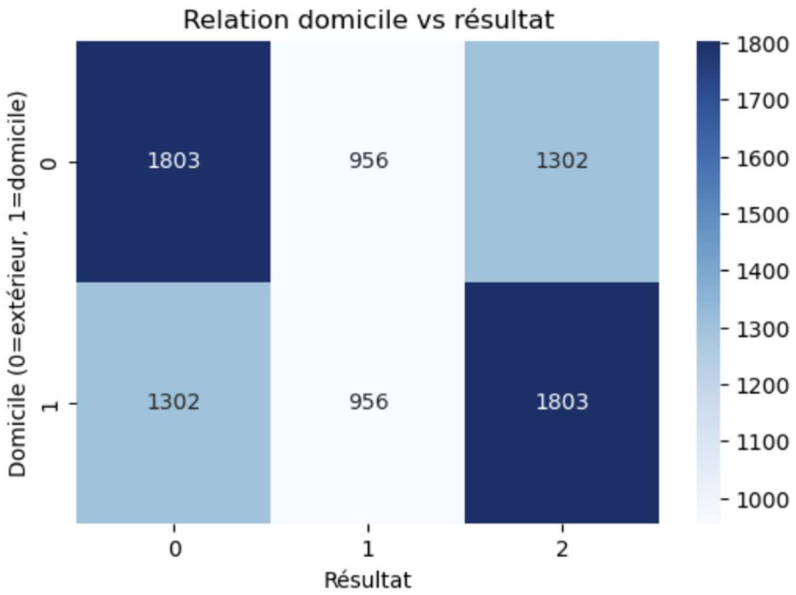

Affluence

L'affluence au stade a été catégorisée en quatre niveaux (faible, moyenne, bonne, grosse affluence) en utilisant les quartiles de distribution calculés saison par saison. Cette approche relative permet de comparer les niveaux d'affluence indépendamment de la capacité des stades.

Variable cible

Une variable cible a été construite pour la modélisation :

- **result_num** : variable ordinale à trois modalités (0 = défaite, 1 = nul, 2 = victoire)

4. Modélisation — Conclusion

Approche et choix du modèle

La modélisation porte sur la prédiction du résultat d'un match (défaite / nul / victoire) à partir des variables construites lors des étapes précédentes. Après une phase exploratoire avec une Régression Logistique et un Random Forest (utilisé pour l'analyse de l'importance des variables), le modèle retenu est un XGBoost Classifier, algorithme de gradient boosting réputé pour ses performances sur des données tabulaires.

Le découpage train/test a été réalisé de manière temporelle : les saisons antérieures à 2023-2024 constituent le jeu d'entraînement, la dernière saison disponible servant de jeu de test. Ce choix évite toute fuite d'information (data leakage) et simule un usage réel du modèle en conditions de prédiction future.

Variables retenues

Le modèle utilise un ensemble de 30 variables couvrant plusieurs dimensions analytiques :

- Contexte du match : réception à domicile (is_home), temps de récupération (rest_days)
- Classement : rang de l'équipe et de l'adversaire, différentiel de rang
- Forme récente : points, buts marqués/encaissés et différentiel de buts sur les 5 derniers matchs (équipe et adversaire)
- Pression de classement : gaps aux seuils clés et scores de pression (équipe et adversaire)
- Variables additionnelles : rivalité, catégorie d'affluence

Résultats, performance et limites

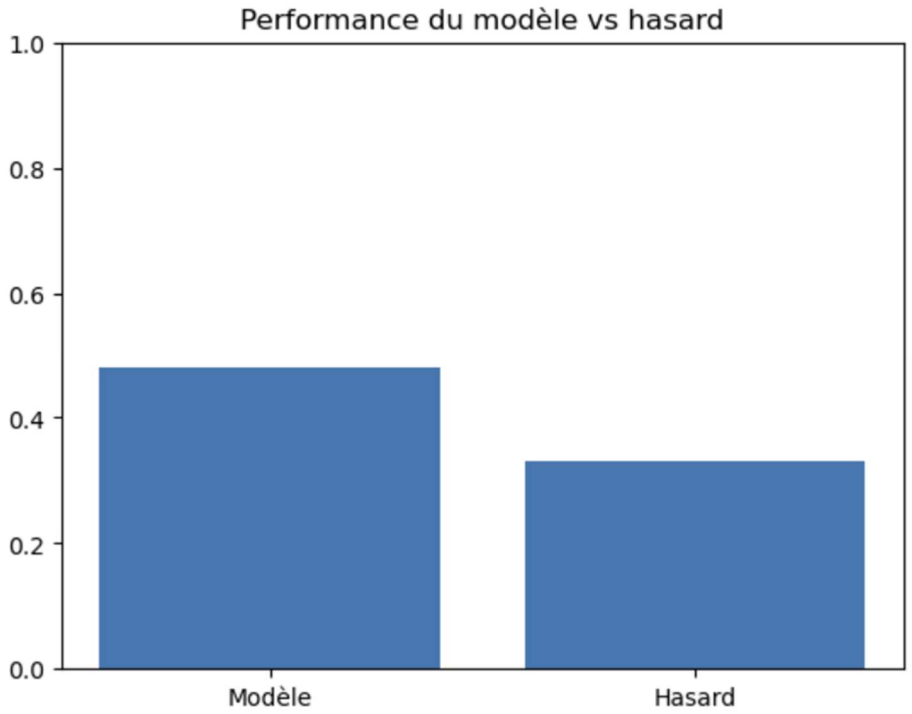

Le modèle atteint une accuracy de 48 % sur l’échantillon test (Saison de 2015 à 2023), contre 33 % pour un classement aléatoire (baseline théorique pour un problème à 3 classes équilibrées). Ce gain de performance confirme que les variables construites contiennent une information prédictive réelle sur l'issue des matchs.

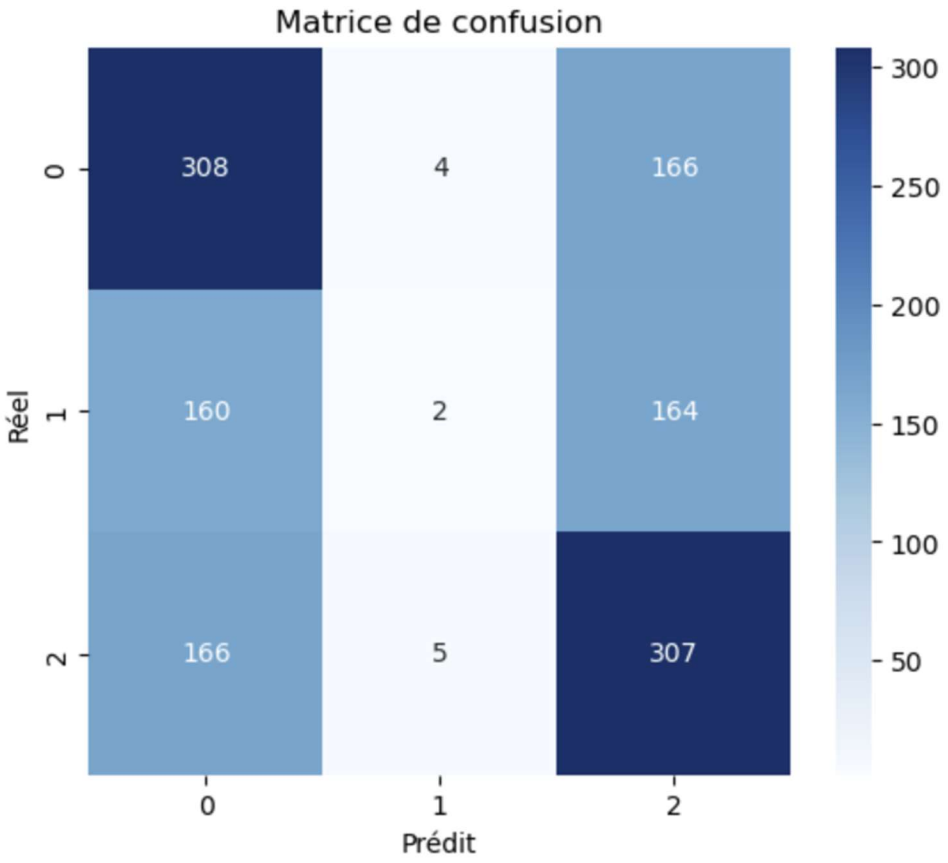

L'analyse des variables importantes (feature importance XGBoost et valeurs SHAP) met en évidence que les indicateurs de forme récente, notamment les points sur les 5 derniers matchs et le différentiel de buts sont les variables les plus discriminantes. Le rang actuel et l'avantage du terrain complètent le tableau des facteurs les plus influents.

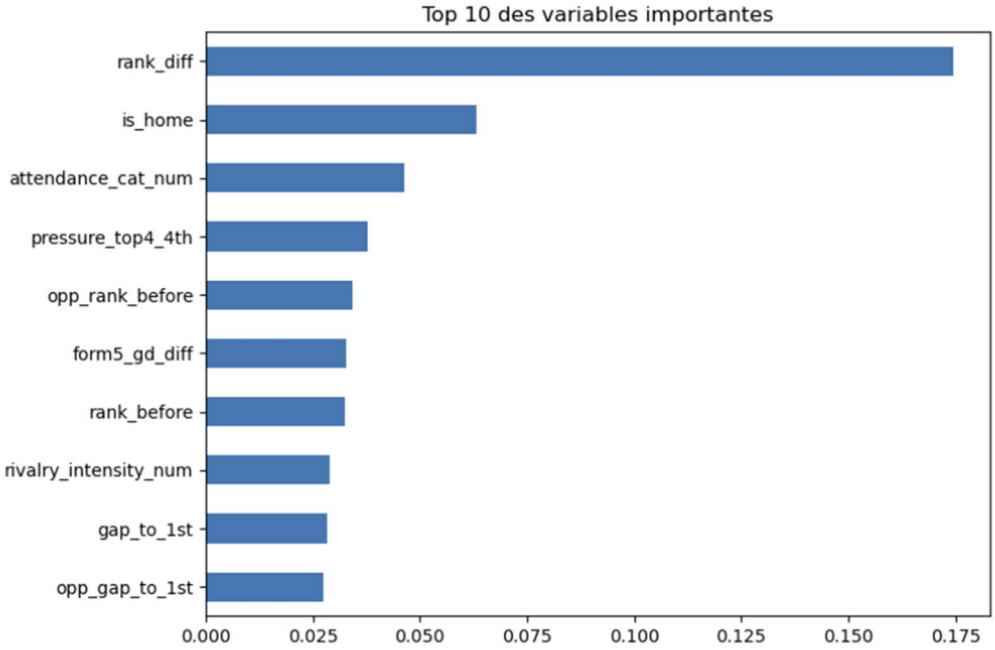

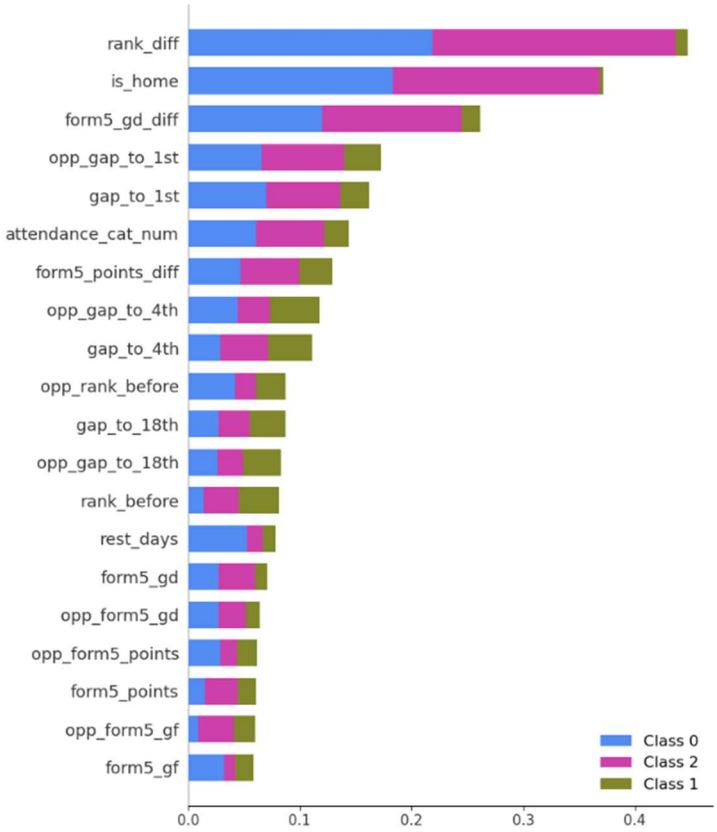

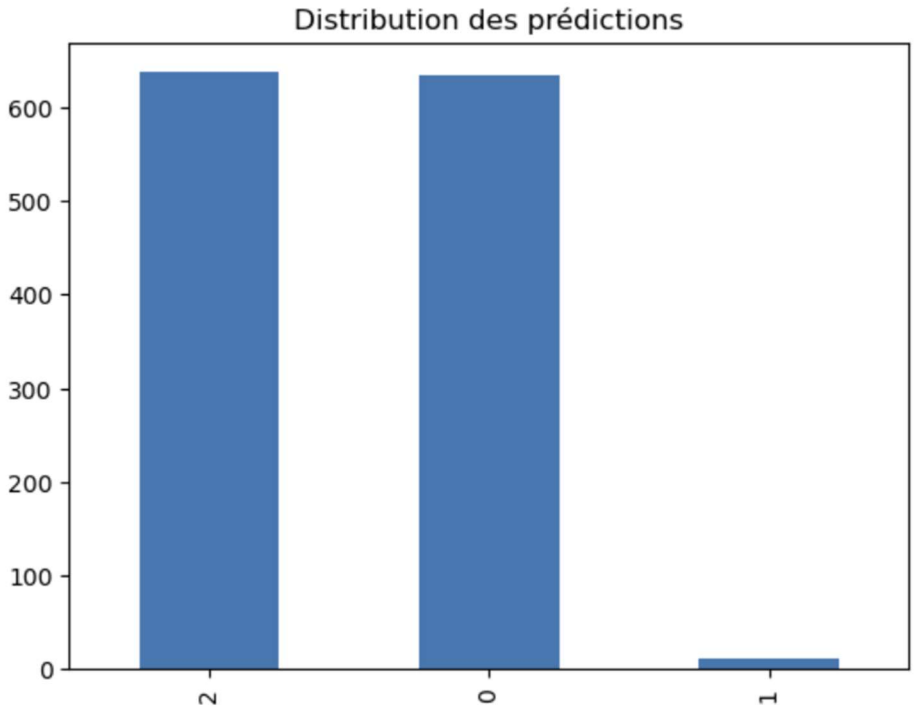

	precision	recall	f1-score	support
0.0	0.49	0.64	0.55	478
1.0	0.18	0.01	0.01	326
2.0	0.48	0.64	0.55	478
accuracy			0.48	1282
macro avg	0.38	0.43	0.37	1282
weighted avg	0.41	0.48	0.41	1282

En revanche, le modèle échoue presque totalement à identifier les matchs nuls, avec un recall très faible (0.01), ce qui indique qu'il ne les prédit quasiment jamais. Ce déséquilibre se reflète également dans les moyennes globales, avec un F1-score pondéré de 0.41.

Globalement, le modèle est performant sur les résultats les plus fréquents mais reste limité sur les cas plus incertains, en particulier les nuls, ce qui est cohérent avec la nature imprévisible de ce type d'issue dans le football.

Plusieurs pistes d'amélioration sont envisageables :

- Intégrer des données de qualité de jeu plus fines (xG, statistiques de pressing, possession)
- Affiner la gestion du déséquilibre de classes entre victoires, nuls et défaites
- Explorer des approches d'ensemble combinant plusieurs modèles complémentaires

Conclusion générale

Ce projet démontre qu'il est possible de dépasser la lecture brute des classements pour construire une représentation plus fidèle de la performance des équipes de Premier League. En intégrant la forme des adversaires, la pression de classement et les conditions de chaque match, les variables construites permettent d'expliquer une part significative de la variance des résultats.

La chaîne complète : scraping, nettoyage, feature engineering et modélisation — constitue un pipeline data analytique robuste et transposable à d'autres championnats ou saisons futures.